Datenbanken und SQL

(Woche 3 - Tag 3)

Agenda

- Gruppierung
  - Definition + Motivation
  - Beispiele
- HAVING-Klausel
  - Definition + Motivation
  - Beispiele

Gruppierung

Definition + Motivation

- Wir haben bisher Aggregat-Funktionen genutzt, um **einzelne Werte** zu ermitteln.
- Entsprechend waren daher die Ausgaben auch jeweils nur **1-zeilig**.
- Dies lag daran, dass wir bei den bisherigen Abfragen alle betrachteten Datensätze – anschaulich gesprochen – **„in einen Topf warfen“** und von diesen dann „die“ Summe (oder „den“ Durchschnittswert, „das“ Minimum … etc.) berechnen ließen.
- Im Folgenden wollen wir uns hierzu eine Variante anschauen, bei der wir die zu berücksichtigenden Datensätze „gruppieren, um daraufhin die zu ermittelnden Aggregatwerte **pro Gruppe** berechnen zu lassen.
- Auf diese Weise werden wir die ermittelten Ergebnisse pro Gruppe vergleichen (oder gegebenenfalls auch sortieren) können und jedenfalls in die Lage versetzt, deutlich **interessantere Abfragen** zu formulieren.

Beispiele

Vorname, Nachname und Anzahl der Abrechnungen **PRO Kunde** (repräsentiert durch Vor- und Nachname):

```
SELECT Vorname, Nachname, COUNT(*) FROM Kunde, Abrechnung
WHERE Kunde.Kunde_ID=Abrechnung.Kunde_ID
GROUP BY Vorname, Nachname;
```

Vorname	Nachname	COUNT(*)
Elli	Rot	2
Eva	Hahn	1
Peter	Kaufnix	1
Rita	Myrnow	1
Vera	Deise	2
Witali	Myrnow	3

Vorname, Nachname und Anzahl der Abrechnungen **PRO Kunde** (repräsentiert durch Vor- und Nachname):
(sortiert nach Anzahl der Abrechnungen absteigend)

```
SELECT Vorname, Nachname, COUNT(*) FROM Kunde, Abrechnung
WHERE Kunde.Kunde_ID=Abrechnung.Kunde_ID
GROUP BY Vorname, Nachname
ORDER BY COUNT(*) DESC;
```

Vorname	Nachname	COUNT(*)
Witali	Myrnow	3
Elli	Rot	2
Vera	Deise	2
Rita	Myrnow	1
Eva	Hahn	1
Peter	Kaufnix	1

Die **Repräsentation eines Kunden** mittels Vor- und Nachnamen ist nicht unproblematisch, da es unterschiedliche, aber gleichnamige Kunden geben könnte, deren Abrechnungen dann fälschlicherweise **„in einen (gemeinsamen) Topf“** geworfen werden würden.

Beispiele

Nachname und Anzahl der Abrechnungen **PRO Kunde** (repräsentiert durch Vor- und Nachname):

```
SELECT Vorname, Nachname, COUNT(*) FROM Kunde, Abrechnung
WHERE Kunde.Kunde_ID=Abrechnung.Kunde_ID
GROUP BY Vorname, Nachname;
```

Vorname	Nachname	COUNT(*)
Elli	Rot	2
Eva	Hahn	1
Peter	Kaufnix	1
Rita	Myrnow	1
Vera	Deise	2
Witali	Myrnow	3

Nachname und Anzahl der Abrechnungen **PRO Kunde** (repräsentiert durch Vor- und Nachname):
(sortiert nach Anzahl der Abrechnungen absteigend)

```
SELECT Vorname, Nachname, COUNT(*) FROM Kunde, Abrechnung
WHERE Kunde.Kunde_ID=Abrechnung.Kunde_ID
GROUP BY Vorname, Nachname
ORDER BY COUNT(*) DESC;
```

Vorname	Nachname	COUNT(*)
Witali	Myrnow	3
Elli	Rot	2
Vera	Deise	2
Rita	Myrnow	1
Eva	Hahn	1
Peter	Kaufnix	1

Die **Repräsentation eines Kunden** mittels Vor- und Nachnamen ist nicht unproblematisch, da es unterschiedliche, aber gleichnamige Kunden geben könnte, deren Abrechnungen dann fälschlicherweise **„in einen (gemeinsamen) Topf“** geworfen werden würden.

Im obigen Fall wäre es also günstiger:

a) die Kunden-ID ausgeben zu lassen
b) nach der Kunden-ID zu gruppieren

Beispiele

Nachname und Anzahl der Abrechnungen **PRO Kunde** (repräsentiert durch Vor- und Nachname):

```
SELECT Vorname, Nachname, COUNT(*) FROM Kunde, Abrechnung
WHERE Kunde.Kunde_ID=Abrechnung.Kunde_ID
GROUP BY Vorname, Nachname;
```

Vorname	Nachname	COUNT(*)
Elli	Rot	2
Eva	Hahn	1
Peter	Kaufnix	1
Rita	Myrnow	1
Vera	Deise	2
Witali	Myrnow	3

Nachname und Anzahl der Abrechnungen **PRO Kunde** (repräsentiert durch Vor- und Nachname):
(sortiert nach Anzahl der Abrechnungen absteigend)

```
SELECT Vorname, Nachname, COUNT(*) FROM Kunde, Abrechnung
WHERE Kunde.Kunde_ID=Abrechnung.Kunde_ID
GROUP BY Vorname, Nachname
ORDER BY COUNT(*) DESC;
```

Vorname	Nachname	COUNT(*)
Witali	Myrnow	3
Elli	Rot	2
Vera	Deise	2
Rita	Myrnow	1
Eva	Hahn	1
Peter	Kaufnix	1

Die **Repräsentation eines Kunden** mittels Vor- und Nachnamen ist nicht unproblematisch, da es unterschiedliche, aber gleichnamige Kunden geben könnte, deren Abrechnungen dann fälschlicherweise **„in einen (gemeinsamen) Topf“** geworfen werden würden.

Im obigen Fall wäre es also günstiger:

a) die Kunden-ID ausgeben zu lassen
b) nach der Kunden-ID zu gruppieren

Dies ist aber dann bereits Teil der Aufgabenstellung und muss bzgl. einer IHK-Aufgabe nicht berücksichtigt werden. So kann für die IHK die folgende Empfehlung ausgesprochen werden: Notieren Sie **hinter GROUP BY** einfach alle Attribute, die auch **hinter SELECT** notiert wurden, **MIT AUSNAHME** der Attribute aller aufgeführten Aggregatfunktionen.

HAVING

Definition + Motivation

- Wie schon WHERE und ON ist auch **HAVING** eine „Bedingungs-Klausel“.
- Sie ist **obligatorisch**, wenn die Bedingung von einem **aggregierten Wert** spricht.
- Auch diese Funktionalität wird uns erlauben, **interessantere Abfragen** zu formulieren. Dies werden wir im Folgenden durch einige Beispiele illustrieren.

Beispiele

PRO Hersteller: Hersteller-Name und Preis seines teuersten Produkts (im Sortiment von „Geld_her“).
(Es sollen aber nur Hersteller berücksichtigt werden, deren **teuerstes Produkt mehr als 30 Euro** kostet.)

```
SELECT Hersteller_Name, MAX(Euro_Preis) FROM Produkt, Hersteller
WHERE Produkt.Hersteller_ID=Hersteller.Hersteller_ID
GROUP BY Hersteller_Name
HAVING MAX(Euro_Preis) > 30;
```

Hersteller_Name	MAX(Euro_Preis)
Contrabit	45.05
Ladenhut AG	1000.00
UltraBug	98.00

PRO Hersteller: Hersteller-Name und Preis seines teuersten Produkts (im Sortiment von „Geld_her“).
(Es sollen aber nur Hersteller berücksichtigt werden, deren **Produkte im Durchschnitt weniger als 500 Euro** kosten.)

```
SELECT Hersteller_Name, MAX(Euro_Preis) FROM Produkt, Hersteller
WHERE Produkt.Hersteller_ID=Hersteller.Hersteller_ID
GROUP BY Hersteller_Name
HAVING AVG(Euro_Preis) < 500;
```

Hersteller_Name	MAX(Euro_Preis)
AntiByte	22.75
Contrabit	45.05
UltraBug	98.00

Stolperfallen und „schlechter Stil“

- Sobald die Aufgabe darin besteht, **aggregierte** und **nicht-aggregierte** Werte **gemeinsam** auszugeben, sollte man „hellhörig“ werden. Hier drohen Stolperfallen.
- Gelegentlich kann man sich zwar über diese Probleme hinwegsetzen, dies gilt aber in der Regel als **schlechter Stil**, oder ist in anderen Fällen sogar schlicht **falsch**.
- In beiden Fällen stellt dies ein Verweis auf **weiterführende Inhalte**, mit denen wir uns zum Teil bereits heute, oder aber in einigen Tagen befassen werden - wir betrachten zunächst 2 Beispiele:

Name und Preis des billigsten Produkts:

```
SELECT Produkt_Name, MIN(Euro_Preis) FROM Produkt;
```

Produkt_Name	MIN(Euro_Preis)
tool 2.0	15.98

Name und Preis des teuersten Produkts:

```
SELECT Produkt_Name, MAX(Euro_Preis) FROM Produkt;
```

Produkt_Name	MAX(Euro_Preis)
tool 2.0	1000.00

Die erste Ausgabe ist nur **zufällig korrekt**, da die erste Entität der Tabelle Produkt zufälligerweise das billigste Produkt ist.

Dies zeigt sich zum einen an der zweiten Ausgabe, zum anderen kann die gesamte Fragestellung problematisiert werden:
„Gibt es überhaupt **das eine** billigste Produkt?“ (oder gibt es mehrere gleich-billige Produkte, die sich diesen „Titel“ teilen?)

Stolperfallen und „schlechter Stil“

- Sobald die Aufgabe darin besteht, **aggregierte** und **nicht-aggregierte** Werte **gemeinsam** auszugeben, sollte man „hellhörig“ werden. Hier drohen Stolperfallen.
- Gelegentlich kann man sich zwar über diese Probleme hinwegsetzen, dies gilt aber in der Regel als **schlechter Stil**, oder ist in anderen Fällen sogar schlicht **falsch**.
- In beiden Fällen stellt dies ein Verweis auf **weiterführende Inhalte**, mit denen wir uns zum Teil bereits heute, oder aber in einigen Tagen befassen werden - wir betrachten zunächst 2 Beispiele:

Name und Preis des billigsten Produkts:

SELECT Produkt_Name**, MIN**(Euro_Preis) **FROM** Produkt**;**

Produkt_Name	MIN(Euro_Preis)
tool 2.0	15.98

Name und Preis des teuersten Produkts:

SELECT Produkt_Name**, MAX**(Euro_Preis) **FROM** Produkt**;**

Produkt_Name	MAX(Euro_Preis)
tool 2.0	1000.00

Die erste Ausgabe ist nur **zufällig korrekt**, da die erste Entität der Tabelle Produkt zufälligerweise das billigste Produkt ist.

Dies zeigt sich zum einen an der zweiten Ausgabe, zum anderen kann die gesamte Fragestellung problematisiert werden:
„Gibt es überhaupt **das eine** billigste Produkt?“ (oder gibt es mehrere gleich-billige Produkte, die sich diesen „Titel“ teilen?)

Erläuterung:

Wir sehen hier ein schönes Beispiel für den „Widerstreit“ zweier Prinzipien. Die interne Schleife startet, gibt den ersten gefundenen Produktnamen aus, und muss dann abbrechen, da die Aggregierte Funktion erst am Ende der Schleife einen Wert ausgeben kann. Wir werden in einigen Tagen eine korrekte Lösung dieser Aufgabenstellung kennenlernen.

Stolperfallen und „schlechter Stil“

Nachname und Anzahl der Abrechnungen von Kunde 2:

```
SELECT Nachname, COUNT(*) FROM Kunde, Abrechnung
WHERE Kunde.Kunde_ID=2
      AND Kunde.Kunde_ID=Abrechnung.Kunde_ID;
```

Nachname	COUNT(*)
Deise	2

Diese Lösung ist zwar korrekt, gilt aber (zumindest aus strenger Sicht) als „schlechter Stil“.

Auch hier wird nämlich einfach der erste gefundene Nachname ausgegeben, der in diesem Fall aber auf Grund der Bedingung **Kunde.Kunde_ID=2** identisch zu den Namen aller anderen Datensätze ist.

Stolperfallen und „schlechter Stil“

Nachname und Anzahl der Abrechnungen von Kunde 2:

```
SELECT Nachname, COUNT(*) FROM Kunde, Abrechnung
WHERE Kunde.Kunde_ID=2
      AND Kunde.Kunde_ID=Abrechnung.Kunde_ID;
```

Nachname	COUNT(*)
Deise	2

Diese Lösung ist zwar korrekt, gilt aber (zumindest aus strenger Sicht) als „schlechter Stil“.

Auch hier wird nämlich einfach der erste gefundene Nachname ausgegeben, der in diesem Fall aber auf Grund der Bedingung **Kunde.Kunde_ID=2** identisch zu den Namen aller anderen Datensätze ist.

Es ist daher **„kein Zufall“**, dass der Nachname (Deise) hier tatsächlich zu dem aggregierten Wert (2) gehört.
Wir wollen aber „kombinierte Ausgaben“ von **aggregierten** und **nicht-aggregierten** Werten zukünftig mittels **„Gruppierungen“** umsetzen.

Dies wird Gegenstand der folgenden Folien sein. Bleiben Sie gespannt ;-)

Gemeinsame Übung („Live-Coding“) -> A_03_03_01

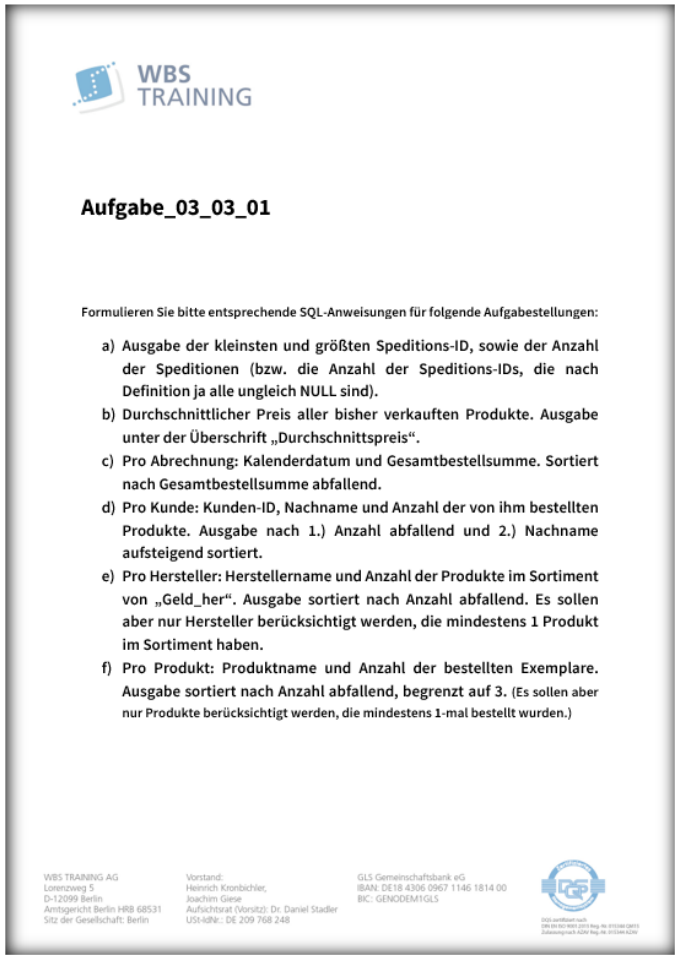

WBS TRAINING

Aufgabe_03_03_01

Formulieren Sie bitte entsprechende SQL-Anweisungen für folgende Aufgabestellungen:

a) Ausgabe der kleinsten und größten Speditions-ID, sowie der Anzahl der Speditionen (bzw. die Anzahl der Speditions-IDs, die nach Definition ja alle ungleich NULL sind).
b) Durchschnittlicher Preis aller bisher verkauften Produkte. Ausgabe unter der Überschrift „Durchschnittspreis“.
c) Pro Abrechnung: Kalenderdatum und Gesamtbestellsumme. Sortiert nach Gesamtbestellsumme abfallend.
d) Pro Kunde: Kunden-ID, Nachname und Anzahl der von ihm bestellten Produkte. Ausgabe nach 1.) Anzahl abfallend und 2.) Nachname aufsteigend sortiert.
e) Pro Hersteller: Herstellername und Anzahl der Produkte im Sortiment von „Geld_her“. Ausgabe sortiert nach Anzahl abfallend. Es sollen aber nur Hersteller berücksichtigt werden, die mindestens 1 Produkt im Sortiment haben.
f) Pro Produkt: Produktname und Anzahl der bestellten Exemplare. Ausgabe sortiert nach Anzahl abfallend, begrenzt auf 3. (Es sollen aber nur Produkte berücksichtigt werden, die mindestens 1-mal bestellt wurden.)

WBS TRAINING AG
Lorenzweg 5
D-12099 Berlin
Amtsgericht Berlin HRB 68531
Sitz der Gesellschaft: Berlin

Vorstand:
Heinrich Kronbichler,
Joachim Giese
Aufsichtsrat (Vorsitz): Dr. Daniel Stadler
USt-IdNr.: DE 209 768 248

GLS Gemeinschaftsbank eG
IBAN: DE18 4306 0967 1146 1814 00
BIC: GENODEM1GLS